

Audit des références

Language Doesn't Matter — commit 361b2c4

10 septembre 2026

Ce qu'il faut savoir en une page

Les 32 références citées par le manuscrit ont été vérifiées auprès des registraires (Crossref, DataCite, PubMed, ACL Anthology). **Aucune n'est inventée** : toutes existent et les métadonnées du fichier `references.bib` sont exactes.

Le problème est ailleurs. **Trois références réelles sont citées pour des affirmations qu'elles ne soutiennent pas**, et une quatrième porte une affirmation factuellement inexacte. Une cinquième erreur a été introduite le 9 septembre lors du dégraissage du manuscrit et a déjà été corrigée.

Référence	Problème
Jiang2020How	Article LPAQA sur le sondage de connaissances factuelles <i>en anglais</i> (« Obama is a __ by profession »). Cité trois fois pour fonder l'avantage du prompt anglais en contexte translinguistique.
Plagwitz2024Zero	Reconnaissance d'entités nommées sur des textes cliniques <i>allemands</i> . Cité pour étayer l'analyse de sentiment en italien et en russe.
Vileikyte2024Sentiment	Fine-tuning de BERT et T5 sur des avis lituaniens. Cité pour un « avantage de la langue locale dans le prompt », question que l'article ne pose pas.
Venerito2024Large	Les entretiens italiens sont <i>traduits en anglais</i> avant analyse. Cité comme démonstration de performance « en italien ».

Par ailleurs, l'affirmation chiffrée la plus vérifiable du manuscrit — « often above 85-95% accuracy across Indo-European, Semitic, and Asian languages » — **n'a pas pu être confirmée** : les éditeurs bloquent le téléchargement automatisé et les résumés ne contiennent pas ces chiffres. La taxonomie qui l'accompagne est en outre incohérente (voir §6).

1 Méthode et niveaux de preuve

Trois niveaux de preuve ont été employés. **Ils ne sont pas équivalents**, et la distinction gouverne tout ce document.

Niveau	Couverture	Ce qu'il permet d'affirmer
Métadonnées	32 / 32	L'article existe ; auteurs, titre, année et DOI sont exacts. Source : API du registre.
Résumé	21 / 32	Le sujet de l'article, tel que ses auteurs le décrivent. Suffit à détecter un contresens sur l'objet, pas sur un résultat chiffré.
Texte intégral	0 / 32	Rien n'a été lu en entier. Aucune affirmation numérique n'est vérifiée.

Limite à retenir. Un audit fondé sur les résumés attrape les erreurs d'objet — citer un article de reconnaissance d'entités pour de l'analyse de sentiment — mais pas les erreurs de degré. Si un article rapporte 78 % d'exactitude et que le manuscrit écrit 85 %, cet audit ne le voit pas. C'est pourquoi la liste A existe.

Un indice de provenance. Sur les 101 entrées du fichier `references.bib`, 62 portent un champ `file` pointant vers une bibliothèque Zotero (`/home/ral/Zotero/storage/...`) absente de ce dépôt. Parmi les 32 références citées, **23 ont un PDF attaché et 9 n'en ont pas**. Ces neuf ont vraisemblablement été ajoutées par import de métadonnées, sans que le texte intégral soit consulté. Elles figurent toutes en liste A ou B.

2 Liste A — à lire intégralement

Dix références. Soit un problème y est avéré, soit elles portent une affirmation chiffrée que seul le texte intégral permet de vérifier. **Aucune ne devrait rester dans le manuscrit sans lecture.**

A.1 — Erreurs avérées (à corriger, pas seulement à lire)

✗ **Jiang2020How** — Jiang, Xu, Araki & Neubig (2020), *How Can We Know What Language Models Know?*, TACL.

Le manuscrit affirme : « a growing body of research reports that prompting in English improves performance on non-English tasks ».

L'article traite de : la génération automatique de prompts pour extraire des connaissances factuelles d'un modèle, en anglais. Le résumé ne mentionne ni multilinguisme ni langue de prompt.

Action : retirer des trois emplacements (Introduction, Revue, Discussion). **Hypothèse à vérifier** : les mêmes auteurs ont publié en 2020 *X-FACTR : Multilingual Factual Knowledge Retrieval from Pretrained Language Models*, qui est multilingue. Une confusion d'entrée Zotero est plausible ; si X-FACTR soutient l'affirmation, la correction se réduit à un changement de clé.

✗ **Plagwitz2024Zero** — Plagwitz et al. (2024), *Zero-Shot LLMs for Named Entity Recognition : Targeting Cardiac Function Indicators*.

Le manuscrit affirme : « Preliminary work with Mistral-7B, LLaMA2, and instruction-tuned models suggests promise in Italian, Russian, and cross-lingual settings ».

L'article traite de : extraction de paramètres médicaux depuis des textes cliniques *allemands*, par reconnaissance d'entités nommées. Ni analyse de sentiment, ni italien, ni russe.

Action : retirer de cette grappe. C'est aussi la seule des quatre références à mentionner Mistral — retirer la référence oblige donc à retirer « Mistral-7B » de l'affirmation, ou à trouver une autre source.

✗ **Vileikyte2024Sentiment** — Vileikytė et al. (2024), *Sentiment Analysis of Lithuanian Online Reviews Using Large Language Models*.

Le manuscrit affirme : « some studies find language-specific prompting advantages ».

L'article traite de : le fine-tuning de BERT et T5 sur des avis lituaniens, avec la conclusion que les modèles affinés battent GPT-4 (80,7 % et 89,6 % d'exactitude). C'est une comparaison *fine-tuning contre généraliste*, pas une comparaison de langues de prompt.

Action : retirer de cette grappe. La phrase « evidence is mixed » repose alors sur Hamalainen2022Video seul — à vérifier d'urgence (liste B), faute de quoi l'affirmation d'un débat n'a plus de support.

! **Venerito2024Large** — Venerito et al. (2024), *Large Language Model-Driven Sentiment Analysis for Facilitating Fibromyalgia Diagnosis*, RMD Open.

Le manuscrit affirme : « promise in Italian ».

L'article précise : « Transcribed responses to questions on pain and sleep were *machine translated to English* and analysed by the LLM Mistral-7B-Instruct-v0.2 ». L'analyse ne porte donc pas sur de l'italien.

Action : corriger l’affirmation. **À noter** : ce cas est en réalité *intéressant* pour votre article — c’est une condition EN→EN appliquée en clinique. Bien reformulé, il devient un appui plutôt qu’une erreur.

A.2 — L’affirmation chiffrée non vérifiée

Cinq références étayent « often above 85-95% accuracy across Indo-European, Semitic, and Asian languages ». Aucun chiffre n’a pu être confirmé.

Référence	Langue	Famille	PDF
Anirban2021Sentiment	bengali	indo-européenne	sans DOI
Michailidis2024Comparative	grec	indo-européenne	MDPI, 403
Rafeef2023Evaluation	arabe	sémitique	accessible
ElJundi2019hULMonA	arabe	sémitique	ACL, lien mort
Ahmadian2024Hybrid	indonésien	austronésienne	Wiley, 403

Deux problèmes distincts.

1. **Le chiffre.** Il faut ouvrir les cinq articles et relever l’exactitude rapportée. Si l’un d’eux se situe à 70 %, l’intervalle « 85-95 » est faux. C’est la vérification la plus facile à faire pour un réviseur, donc la plus risquée à négliger.
2. **Une référence détonne.** Rafeef2023Evaluation porte sur l’évaluation d’hôtels à partir d’avis en arabe, publiée dans une revue de technologies mobiles interactives. C’est une application sectorielle, appui faible pour une affirmation générale sur la performance translinguistique. Envisager de la retirer.

A.3 — Un soutien réel, mais sur un autre mécanisme

! Muennighoff2023Crosslingual — Muennighoff et al. (2023), *Crosslingual Generalization through Multitask Finetuning*, ACL.

Le résumé dit : « finetuning large multilingual language models on English tasks with English prompts allows for task generalization to non-English languages » et « Finetuning on multilingual tasks with English prompts further improves performance ».

Nuance : il s’agit d’un effet du **fine-tuning** avec prompts anglais, non du prompting à l’inférence — ce que votre étude mesure. Les deux mécanismes sont distincts.

Action : conserver, mais préciser la distinction dans le texte. C’est à votre avantage : cela montre que la question posée à l’inférence reste ouverte, ce qui renforce la justification de l’étude.

3 Liste B — à vérifier sur un point précis

Quatorze références. Le résumé est cohérent avec l’usage qu’en fait le manuscrit, ou n’a pas pu être récupéré. Une lecture ciblée suffit : résumé, tableau de résultats, conclusion.

Référence	Point à vérifier	État
Hamalainen2022Video	Trouve-t-il vraiment un avantage de la langue locale? Devient le <i>seul</i> support de « evidence is mixed » si Vileikyte est retirée.	prioritaire
Lin2022Few	Contient-il des expériences sur la <i>langue du prompt</i> ? Le résumé porte sur la capacité multilingue, pas sur le prompting.	résumé lu

Référence	Point à vérifier	État
Nie2024Decomposed	Porte sur l'étiquetage de séquences et le maintien de gabarits de sortie. Soutient-il l'avantage du prompt anglais ?	résumé lu
Pan2023Evaluation	Cité pour le transfert translinguistique ; le résumé porte sur la prédiction boursière à partir de données financières.	résumé lu
Kumar2021Sentiment	Cité pour le transfert translinguistique ; résumé centré sur les médias sociaux.	résumé lu
Rusnachenko2024Large	Russe et LLM affinés par instruction : concordance apparente. Vérification légère.	résumé lu
Buscemi2024ChatGPT	LLaMA2 et 10 langues : concordance apparente. Vérification légère.	résumé lu
Tela2024Transferring	Langues peu dotées : concordance apparente.	résumé lu
Salahudeen2023HausaNL	SemEval-2023 tâche 12, langues africaines : concordance apparente.	résumé lu
Nazir2025Leveraging	Aucun résumé récupéré.	non vérifié
Kotelnikova2023Cross	Aucun résumé récupéré.	non vérifié
Francesco2021XLM	Aucun DOI, aucun résumé.	non vérifié
Mikhail2024Multilingual	Aucun DOI, aucun résumé.	non vérifié
Priban2024comparative	Aucun DOI, aucun résumé. Citée deux fois.	non vérifié

Les cinq marquées « non vérifié » n'ont *aucune* preuve au-delà de leur présence dans le fichier .bib. Quatre d'entre elles n'ont pas de DOI, ce qui empêche même la vérification d'existence. **Ce sont les premières à traiter dans cette liste.**

4 Liste C — utilisables sans relecture

Huit références. Le résumé confirme la concordance avec l'usage qu'en fait le manuscrit, et l'affirmation portée est consensuelle. Le risque est faible et le coût d'une erreur le serait aussi.

Référence	Affirmation portée
touvron_etal23a	Les modèles sont entraînés majoritairement sur des données anglaises. Article Llama, non contesté.
Laurer2023Less	L'apprentissage supervisé exige des milliers d'annotations. Résumé : concordance exacte.
Chalkidis2020LEGAL	L'adaptation de BERT à un domaine exige de l'expertise. Résumé : concordance.
Strubell2019Energy	Coût computationnel de l'entraînement. Référence standard.
Perron2024Demystifying	Les API rendent les LLM accessibles aux chercheurs en sciences sociales. Résumé : concordance exacte.
Ghosh2023Navigating	Même affirmation. Concordance plus lâche (l'article porte sur GPT-4 en finance et en politique) mais l'enjeu est faible.
duval_petry16	Source du dictionnaire français fr1sd. Référence méthodologique standard.
young_andsoroka12	Source du <i>Lexicoder Sentiment Dictionary</i> . Référence méthodologique standard.

Une correction matérielle : duval_petry16 et young_andsoroka12 portent tous deux un champ `date` = 2025-04-02, qui est une date d'import Zotero et non de publication. À corriger dans le fichier .bib : les deux articles datent respectivement de 2016 et 2012.

5 Liste D — les sept références ajoutées le 10 septembre

Ces sept références ont été ajoutées au fichier `references.bib` pour combler l'absence de travaux 2025–2026, mais **ne sont encore citées nulle part dans le manuscrit**. Elles ne peuvent donc pas encore être mal citées — mais elles le seront dès leur intégration si elles ne sont pas lues d'abord.

Leur niveau de preuve est plus faible que celui des 32 autres. Pour cinq d'entre elles, la seule information de contenu dont on dispose est un extrait de moteur de recherche — une synthèse automatique qui agrège plusieurs sources sans les distinguer. C'est précisément le mode de défaillance qui produit une citation mal fondée.

Référence	Ce qu'elle doit étayer	Preuve nible	dispo-	Priorité
richie_etal22	L'accord intercodeurs n'est pas une borne supérieure stricte de la performance machine.	Résumé du PDF, lu par un outil automatique		critique
nguyen_etal26	La langue du prompt n'est pas neutre : elle modifie la forme de la sortie sans altérer le sens.	Résumé de la page arXiv		critique
gupta_etal25	Traduire <i>une partie</i> du prompt bat le tout-anglais comme le tout-langue-source.	Extrait de recherche	seulement	haute
beauchemin_etal25	Banc d'essai français; écarts entre modèles à poids ouverts et fermés.	Extrait de recherche	seulement	haute
kastrati_etal26	Analyse de sentiment translinguistique par familles de langues.	Extrait de recherche	seulement	moyenne
langlais_etal26	Sentiment en français; modèles spécialisés contre gros LLM.	Extrait de recherche	seulement	moyenne
boguslav_cohen17	Antécédent de richie_etal22.	Métadonnées	seulement	basse

Les deux critiques, et pourquoi

! richie_etal22 — Richie, Grover & Tsui (2022), *Inter-annotator agreement is not the ceiling of machine learning performance*, BioNLP.

Cette référence est destinée à étayer une **reformulation de votre résultat le plus fort**. Le calcul du plafond humain ($r = 0,748$, sept combinaisons modèle-condition au-dessus) est exact, mais la littérature conteste que l'accord intercodeurs constitue une borne supérieure. La formulation « les modèles dépassent la performance humaine » devient donc indéfendable, au profit de « les modèles atteignent le niveau d'accord que les codeurs humains obtiennent entre eux ».

Si cet article ne dit pas ce qui lui est attribué ici, cette reformulation perd son appui.

C'est la lecture la plus rentable de toute la liste.

! nguyen_etal26 — Nguyen et al. (2026), *Investigating the Influence of Prompt and Response Languages on LLM Content Generation*.

C'est le travail le plus directement concurrent du vôtre : il conclut que « la langue du prompt n'est pas neutre », ce qui contredit votre résultat en apparence. La distinction qui réconcilie les deux — ils mesurent la *forme* de la sortie (longueur, réalisation lexicale), vous mesurez une note numérique, donc le *sens* — repose sur un résumé, pas sur une lecture. Si elle ne tient pas, votre positionnement par rapport à ce travail doit être repensé.

PDF — six sur sept librement accessibles

Référence	Adresse
richie_etal22	https://aclanthology.org/2022.bionlp-1.26.pdf
nguyen_etal26	https://arxiv.org/pdf/2608.26186
gupta_etal25	https://arxiv.org/pdf/2507.22923
beauchemin_etal25	https://arxiv.org/pdf/2510.05046
langlais_etal26	https://arxiv.org/pdf/2604.18226
kastrati_etal26	https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2026.1854873/pdf
boguslav_cohen17	IOS Press — erreur 403. Accès institutionnel requis, ou à abandonner : richie_etal22 couvre le même argument plus récemment.

Une remarque sur beauchemin_etal25

Le banc d'essai COLE est signé par David Beauchemin et Richard Khoury, du département d'informatique et de génie logiciel de l'**Université Laval**. Il porte sur l'évaluation du français et documente les écarts entre modèles à poids ouverts et fermés — c'est-à-dire votre question de recherche n° 2, traitée sur le même campus. Ne pas le citer serait remarqué. Une conversation avec ces collègues avant soumission pourrait par ailleurs être utile.

6 La taxonomie des familles linguistiques

Le manuscrit écrit « across Indo-European, Semitic, and *Asian* languages ». L'énumération mêle deux familles linguistiques et une catégorie géographique, ce qui la rend incohérente :

- le **bengali** (Anirban2021) est indo-européen *et* asiatique ;
- l'**indonésien** (Ahmadian2024) est austronésien, pas « asiatique » au sens familial ;
- aucune langue **sino-tibétaine, japonique ou coréenne** n'est représentée — celles qu'un lecteur associe spontanément au mot « asiatiques ».

Correction proposée : « across Indo-European, Semitic, and Austronesian languages », ou plus simplement une énumération par langue (« en grec, bengali, arabe et indonésien »), qui est à la fois exacte et plus informative.

7 PDF à récupérer

Librement accessibles — à télécharger

Référence	Adresse
Vileikyte2024Sentiment	https://arxiv.org/pdf/2407.19914
Muennighoff2023Cross...	https://aclanthology.org/2023.acl-long.891.pdf
Lin2022Few	https://aclanthology.org/2022.emnlp-main.616.pdf
Nie2024Decomposed	https://arxiv.org/pdf/2402.18397
Rafeef2023Evaluation	https://doi.org/10.3991/ijim.v17i09.38755

Bloqués pour un accès automatisé — accès institutionnel requis

Ces éditeurs renvoient une erreur 403 aux requêtes automatisées. **Ils sont normalement accessibles depuis le réseau de l'Université Laval**, ou via le proxy de la bibliothèque.

Référence	Éditeur	Priorité
Jiang2020How	MIT Press (TACL)	critique
Plagwitz2024Zero	IOS Press	critique
Venerito2024Large	BMJ (RMD Open)	critique
Michailidis2024Comparative	MDPI	haute (chiffre)
Ahmadian2024Hybrid	Wiley	haute (chiffre)
Hamalainen2022Video	ACM	haute
Pan2023Evaluation	PeerJ	moyenne
Kumar2021Sentiment	ACM	moyenne

Problèmes d'accès particuliers

- ElJundi2019hULMonA — le DOI ACL (10.18653/v1/w19-4608) renvoie une erreur 404 sur l’anthologie. À rechercher manuellement dans les actes du *Fourth Arabic Natural Language Processing Workshop* (2019).
- Anirban2021Sentiment — **aucun DOI dans le fichier .bib**. Impossible de vérifier même son existence. À retrouver et compléter, ou à retirer.
- Francesco2021XLM, Mikhail2024Multilingual, Priban2024comparative, trovron_etal23a — également sans DOI. Les trois premières sont non vérifiées ; la quatrième est identifiable (article Llama).

La solution durable

Vingt-trois des trente-deux références citées ont déjà un PDF dans la bibliothèque Zotero de ral. **Un export Zotero avec pièces jointes, ou un groupe Zotero partagé**, réglerait la majeure partie du problème d'accès d'un coup — et mettrait tous les coauteurs sur la même base pour la suite. C'est la démarche à privilégier avant d'aller chercher les PDF un par un.

8 Les 69 entrées non citées

Le fichier `references.bib` contient 101 entrées dont 32 seulement sont citées. Les 69 restantes ne posent aucun problème en l'état — elles n'apparaissent pas dans le document rendu. Elles méritent toutefois un examen avant soumission, pour deux raisons : certaines couvrent peut-être déjà les lacunes de la revue de littérature identifiées par ailleurs (absence de travaux 2025–2026), et leur présence suggère qu'une recherche plus large a été amorcée sans être intégrée au texte.

9 Ce que cet audit ne couvre pas

Par honnêteté sur sa portée :

- **Aucun article n'a été lu en entier**. Les verdicts reposent sur les résumés rédigés par les auteurs, récupérés auprès des registraires.
- **Aucune affirmation numérique n'est vérifiée**. L'intervalle « 85-95 % » reste ouvert, ainsi que toute autre valeur chiffrée attribuée à une source.
- **Onze résumés sur trente-deux n'ont pas pu être récupérés**. Pour ces références, la vérification s'arrête aux métadonnées.
- **Les sept références ajoutées le 10 septembre** (liste D) reposent sur une preuve encore plus mince : cinq d'entre elles ne sont étayées que par un extrait de moteur de recherche, et les deux autres par un résumé produit automatiquement. Leurs métadonnées sont vérifiées ; leur contenu ne l'est pas.

-
- **L'adéquation entre l'affirmation et la source** a été évaluée sur l'objet de l'article, non sur la finesse de ses résultats. Un article peut porter sur le bon sujet et ne pas soutenir la nuance exacte qu'on lui fait porter.
-

Audit produit le 10 septembre 2026. Métadonnées vérifiées auprès de Crossref, DataCite, PubMed et ACL Anthology. Les citations du manuscrit ont été extraites de `docs/pub/pub.qmd` au commit `361b2c4`. Une cinquième erreur — des citations laissées attachées à une phrase réécrite le 9 septembre — a été corrigée avant la production de ce document.